第 3 节　变量间的相关关系及回归模型

考点一	成对数据的相关性

1. 相关关系及分类

（1）相关关系：若两个变量有关系，但又没有确切到可由其中的一个去精确地决定另一个的程度，这种关系称为相关关系；

（2）分类：①从整体上看，当一个变量的值增加时，另一个变量的相应值也呈现增加的趋势，就称这两个变量_____；

②当一个变量的值增加时，另一个变量的相应值呈现减小的趋势，则称这两个变量_____.

提醒： 注意相关关系与函数关系的区别：函数关系是一种确定的关系，而相关关系是一种非确定的关系.

2. 线性相关： 一般地，如果两个变量的取值呈现正相关或负相关，而且散点落在_____附近，就称这两个变量线性相关.

3. 样本相关系数

对于变量 x 和变量 y，设经过随机抽样获得的成对样本数据为（x_1，y_1），（x_2，y_2），…，（x_n，y_n），若 x 与 y 存在线性相关关系，可用样本相关系数 r 定量分析它们的相关程度的强弱.

（1）样本相关系数 $r=\dfrac{\sum\limits_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sqrt{\sum\limits_{i=1}^{n}(x_i-\overline{x})^2}\sqrt{\sum\limits_{i=1}^{n}(y_i-\overline{y})^2}}$（为 x_1，x_2，…，x_n 的平均数，$\overline{y}$ 为 y_1，y_2，…，y_n 的平均数）；

（2）样本相关系数 r 的性质

①当 $r>0$ 时，称成对样本数据_____相关；当 $r<0$ 时，称成对样本数据_____相关；当 $r=0$ 时，称成对样本数据间没有线性相关关系；

②样本相关系数 r 的取值范围为_____. 当 $|r|$ 越接近 1 时，成对样本数据的线性相关程度越_____；当 $|r|$ 越接近 0 时，成对样本数据的线性相关程度越_____.

例 1 （1）对变量 x，y 有观测数据（x_i，y_i）（$i=1$，2，3，…，10），得散点图 1；对变量 u，v 有观测数据（u_i，v_i）（$i=1$，2，3，…，10），得散点图 2. 由这两个散点图可以判断（　　）

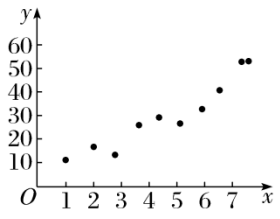


图 1

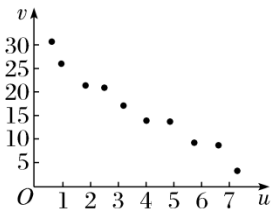


图 2

A. 变量 x 与 y 正相关，u 与 v 正相关

B. 变量 x 与 y 正相关，u 与 v 负相关

C. 变量 x 与 y 负相关，u 与 v 正相关

D. 变量 x 与 y 负相关，u 与 v 负相关

（2）近年来，“双 11”网购的观念逐渐深入人心，某人统计了近 5 年某网站“双 11”当天的交易额，统计结果如下表：

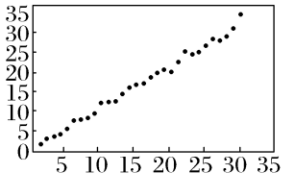
年份	2021	2022	2023	2024	2025
年份代码 x	1	2	3	4	5

交易额 y/百亿元	9	12	17	21	26

请根据表中提供的数据，画出散点图，推断两个变量是否线性相关，并用样本相关系数 r 说明 y 与 x 的线性相关程度.（结果保留三位小数）

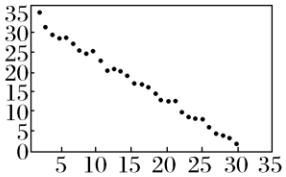
附：$r=\frac{\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\overline{x})^2}\sqrt{\sum_{i=1}^{n}(y_i-\overline{y})^2}}=\frac{\sum_{i=1}^{n}x_iy_i-n\overline{x}\cdot\overline{y}}{\sqrt{\sum_{i=1}^{n}x_i^2-n\overline{x}^2}\sqrt{\sum_{i=1}^{n}y_i^2-n\overline{y}^2}}$，$\sqrt{465}\approx21.564$.

练 1 对四组数据进行统计，获得如图所示的散点图，关于其样本相关系数的比较，正确的是（　　）



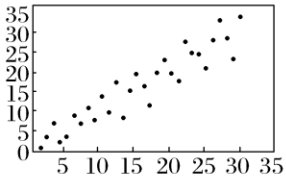
样本相关系数为r_1

图 1



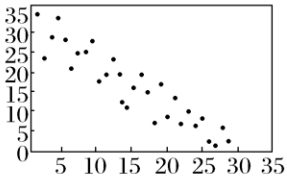
样本相关系数为r_2

图 2



样本相关系数为r_3

图 3



样本相关系数为 r_4

图 4

A. $r_2<r_4<0<r_3<r_1$

B. $r_4<r_2<0<r_1<r_3$

C. $r_4<r_2<0<r_3<r_1$

D. $r_2<r_4<0<r_1<r_3$

考点二	一元线性回归模型

1. 经验回归直线：从散点图上看，如果这些点从整体上看大致分布在通过散点图中心的一条直线附近，这条直线叫做经验回归直线.

2. 经验回归直线对应的方程称为经验回归方程，即$\hat{y}=\hat{b}x+\hat{a}$，其中$\hat{b}=\frac{\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sum_{i=1}^{n}(x_i-\overline{x})^2}=\frac{\sum_{i=1}^{n}x_iy_i-n\overline{xy}}{\sum_{i=1}^{n}x_i^2-n\overline{x}^2}$，$\hat{a}=\overline{y}-\hat{b}\overline{x}$；其中$\hat{b}>0$ 表明线性正相关，$\hat{b}<0$ 表明线性负相关.

3. 通过求 $Q=\sum_{i=1}^{n}(y_i-bx_i-a)^2$ 的最小值而得到经验回归直线的方法，即使得样本数据的点到回归直线的距离的平方和最小，这一方法叫做最小二乘法.

结论：经验回归直线经过样本中心点（$\overline{x}$，$\overline{y}$）.

例 2 某企业近年来的广告费用 x（单位：百万元）与所获得的利润 y（单位：千万元）的数据如表所示，已知 y 与 x 之间具有线性相关关系.

年份	2021	2022	2023	2024	2025
广告费用 x/百万元	1.5	1.6	1.7	1.8	1.9
利润 y/千万元	1.6	2	2.4	2.5	3

（1）求 y 关于 x 的经验回归方程；

（2）若该企业从 2021 年开始，广告费用连续每一年都比上一年增加 10 万元，根据（1）中所得的经验回归方程，预测 2028 年该企业所获得的利润.

参考公式：$\hat{b}=\frac{\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sum_{i=1}^{n}(x_i-\overline{x})^2}=\frac{\sum_{i=1}^{n}x_iy_i-n\overline{xy}}{\sum_{i=1}^{n}x_i^2-n\overline{x}^2}$，$\hat{a}=\overline{y}-\hat{b}\overline{x}$.

练 2 小李准备在某商场租一间商铺开服装店，为了解市场行情，在该商场调查了 20 家服装店，统计得到了它们的面积 x（单位：m^2）和日均客流量 y（单位：百人）的数据（x_i，y_i）（$i=1,2,\cdots,20$），并计算得 $\sum_{i=1}^{20}x_i=2400$，$\sum_{i=1}^{20}y_i=210$，$\sum_{i=1}^{20}(x_i-\overline{x})^2=42\,000$，$\sum_{i=1}^{20}(x_i-\overline{x})(y_i-\overline{y})=6\,300$.

（1）求 y 关于 x 的经验回归方程；

（2）已知服装店每天的经济效益 $W=k\sqrt{y}+mx$（$k>0$，$m>0$），该商场现有 60～150 m^2 的商铺出租，根据（1）的结果进行预测，要使单位面积的经济效益 Z 最高，小李应该租多大面积的商铺？

附：回归直线 $\hat{y}=\hat{b}x+\hat{a}$ 的斜率和截距的最小二乘估计分别为：$\hat{b}=\frac{\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sum_{i=1}^{n}(x_i-\overline{x})^2}$，$\hat{a}=\overline{y}-\hat{b}\overline{x}$.

考点三	刻画拟合效果的统计量

刻画拟合效果的统计量：（1）残差：$e_i=y_i-\hat{y}_i$：残差图法：残差点比较均匀地落在水平的带状区域内说明选用的模型比较合适；

（2）残差平方和：$\sum\limits_{i=1}^{n}(y_i-\hat{y}_i)^2$；残差平方和越小，模型的拟合效果越好；

（3）决定系数：$R^2=1-\dfrac{\sum\limits_{i=1}^{n}(y_i-\hat{y}_i)^2}{\sum\limits_{i=1}^{n}(y_i-\overline{y})^2}$，$R^2$越接近 1，表明模型的拟合效果越好.（其中 y_i为观测值，$\hat{y}_i$为预测值，$\overline{y}$为观测值的平均数）.

例 3 假定小麦基本苗数 x 与成熟期有效穗 y 之间存在相关关系，今测得 5 组数据如下：

x	15. 0	25. 8	30. 0	36. 6	44. 4
y	39. 4	42. 9	42. 9	43. 1	49. 2

若由最小二乘法计算得经验回归方程为$\hat{y}=0.29x+34.7$.

（1）计算各组残差，并计算残差平方和；

（2）求 R^2，并说明回归模型拟合效果的好坏.

参考数据：$\sum\limits_{i=1}^{5}(y_i-\overline{y})^2=50.18$.

练 3 在一元线性回归模型 $Y=bx+a+e$ 中，下列说法正确的是（　　）

A. $Y=bx+a+e$ 是一次函数

B. 响应变量 Y 是由解释变量 x 唯一确定的

C. 响应变量 Y 除了受解释变量 x 的影响外，可能还受到其他因素的影响，这些因素会导致随机误差 e 的产生

D. 随机误差 e 是由于计算不准确造成的，可通过精确计算避免随机误差 e 的产生

提能点	非线性回归模型的应用

例 4 （1）若一函数模型为 $y=\sin^2\alpha+2\sin\alpha+1$，为将 y 转化为 t 的线性经验回归方程，则需作变换 t 等于（　　）

A. $\sin^2\alpha$　　B. $(\sin\alpha+1)^2$

C. $(\sin\alpha+\frac{1}{2})^2$　　D. 以上都不对

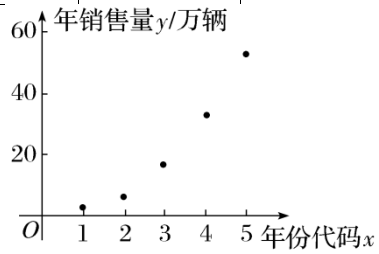
（2）用模型 $y=c\cdot e^{kx}$ 拟合一组数据时，为了求出非线性回归方程，设 $z=\ln y$，其变换后得到线性回归方程为 $\hat{z}=0.5x+1$，则 $c=$（　　）

A. 0.5　　B. e

C. 2　　D. e^2

练 4 “绿水青山就是金山银山”的理念推动了新能源汽车产业的迅速发展. 以下表格和散点图反映了近几年某新能源汽车的年销售量情况.

年份	2021	2022	2023	2024	2025
年份代码 x	1	2	3	4	5
某新能源汽车年销售量 y/万辆	1.5	5.9	17.7	32.9	55.6



（1）请根据散点图判断，$y=bx+a$ 与 $y=cx^2+d$ 中哪一个更适宜作为年销售量 y 关于年份代码 x 的回归方程类型；（给出判断即可，不必说明理由）

（2）根据（1）的判断结果及表中数据，建立 y 关于 x 的经验回归方程，并预测 2026 年该新能源汽车的年销售量.（精确到 0.1）

参考数据：$\overline{y}=22.72$，$\sum\limits_{i=1}^{5}(w_i-\overline{w})^2=374$，$\sum\limits_{i=1}^{5}(w_i-\overline{w})(y_i-\overline{y})=851.2$（其中 $w_i=x_i^2$）.